Book Sales Data Analysis

Data Cleaning Exploration Visualization

End to End Project

Background

Sebuah toko buku memiliki data penjualan besar yang belum dimanfaatkan secara optimal. Analisis ini hadir untuk mengubah data menjadi keputusan bisnis yang tepat.

Goals

📦 Stok Tepat Sasaran

Menentukan buku yang perlu diperbanyak sesuai permintaan pasar

📚 Genre Unggulan

Memilih genre dan judul yang paling menguntungkan

🤝 Mitra Terbaik

Memperkuat kerja sama dengan publisher dan author terlaris

🌍 Pasar Lebih Luas

Memperluas jangkauan pasar secara lebih terarah

Objective

Memastikan dataset penjualan buku dalam kondisi bersih, konsisten, dan siap untuk dianalisis lebih lanjut.

Tools

Python (Pandas Library)

Initial Data Inspection

- df(head) digunakan untuk menampilkan beberapa baris pertama dataset secara keseluruhan.

```
df.head()
```

	index	Publishing Year	Book Name	Author	language_code	Author_Rating	Book_average_rating	Book_ratings_count	genre	gross sales	publisher revenue	sale price	sale ran
0	0	1975.0	Beowulf	Unknown, Seamus Heaney	en-US	Novice	3.42	155903	genre fiction	34160.0	20496.0	4.88	
1	1	1987.0	Batman: Year One	Frank Miller, David Mazzucchelli, Richmond Lew...	eng	Intermediate	4.23	145267	genre fiction	12437.5	7462.5	1.99	
2	2	2015.0	Go Set a Watchman	Harper Lee	eng	Novice	3.31	138669	genre fiction	47795.0	28677.0	8.69	
3	3	2008.0	When You Are Engulfed in Flames	David Sedaris	en-US	Intermediate	4.04	150898	fiction	41250.0	24750.0	7.50	
4	4	2011.0	Daughter of Smoke & Bone	Laini Taylor	eng	Intermediate	4.04	198283	genre fiction	37952.5	22771.5	7.99	

- df(info) digunakan untuk mengecek:
  - Tipe data setiap kolom
  - Jumlah non-null values

```
Data columns (total 15 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   index                 1070 non-null   int64
 1   Publishing Year       1069 non-null   float64
 2   Book Name             1047 non-null   object
 3   Author                1070 non-null   object
 4   language_code         1017 non-null   object
 5   Author_Rating         1070 non-null   object
 6   Book_average_rating   1070 non-null   float64
 7   Book_ratings_count    1070 non-null   int64
 8   genre                 1070 non-null   object
 9   gross sales           1070 non-null   float64
 10  publisher revenue     1070 non-null   float64
 11  sale price            1070 non-null   float64
 12  sales rank            1070 non-null   int64
 13  Publisher             1070 non-null   object
 14  units sold            1070 non-null   int64
```

Data Cleaning Process

1. Handling missing value

df.isna().any() = Mengecek missing values per kolom

- True: terdapat data kosong pada kolom
- False: tidak terdapat data kosong

df.dropna() = Menghapus baris yang mengandung data kosong untuk memastikan dataset lengkap sebelum analisis.

index	False
Publishing Year	True
Book Name	True
Author	False
language_code	True
Author_Rating	False
Book_average_rating	False
Book_ratings_count	False
genre	False
gross sales	False
publisher revenue	False
sale price	False
sales rank	False
Publisher	False
units sold	False

index	False
Publishing Year	False
Book Name	False
Author	False
language_code	False
Author_Rating	False
Book_average_rating	False
Book_ratings_count	False
genre	False
gross sales	False
publisher revenue	False
sale price	False
sales rank	False
Publisher	False
units sold	False

2. Removing Irrelevant Columns

Kolom yang dihapus: index, sales rank, author rating

Alasan: Ketiga kolom tersebut tidak relevan dan tidak berkontribusi signifikan terhadap analisis penjualan.

```
#hapus kolom index, sales rank dan author rating
df = df.drop('index', axis=1)
df = df.drop('sales rank', axis=1)
df = df.drop('Author_Rating', axis=1)
df.head()
```

Data Cleaning Process

3. Data Type Correction

Kolom Publishing Year diubah dari format float (1975.0) menjadi integer (1975) untuk menjaga konsistensi tipe data numerik.

4. Genre Standardization

Ditemukan inkonsistensi pada kolom genre, yaitu terdapat dua kategori yang merujuk pada hal yang sama: "fiction" dan "genre fiction".

Keduanya digabungkan menjadi satu kategori "fiction" menggunakan perintah df['genre'].str.replace('genre', '', case=False, regex=False).

Kategori lain seperti nonfiction dan children sudah dalam kondisi konsisten dan tidak perlu diubah.

genre	
genre fiction	772
nonfiction	156
fiction	55
children	15

genre	
fiction	827
nonfiction	156
children	15

5. Finalization

Dataset yang telah dibersihkan diekspor kembali untuk tahap analisis dan visualisasi data.

EDA Overview

Objective

Mengeksplorasi dataset penjualan buku untuk menemukan pola dan insight bisnis yang relevan.

Jumlah Data

971 data buku setelah proses cleaning

Tools

Microsoft Excel (Pivot Table)

Fokus Analisis

- Penjualan buku terlaris
- Publisher dan author terlaris
- Genre terlaku
- Top author berdasarkan rating
- Pasar berdasarkan bahasa buku

Exploratory Data Analysis

TOP 10 Penjualan Buku Terbanyak		
Judul Buku	Total Unit Terjual	Total Gross Sales
New Moon: The Complete Illustrated Movie C	61.560	1.560,580
Maybe Someday	61.128	969,860
Mr Maybe	61.128	562,590
Anne of the Island	60.696	139,590
Also sprach Zarathustra	59.400	1.030,710
North and South	58.968	562,590
A Stolen Life	57.240	558,600
The Immortals of Meluha	56.808	418,600
The Lost World	55.728	1.398,600
Requiem	55.080	698,600
Grand Total	**587.736**	**7.900,320**

Publisher Terlaris		
Publisher	Total Unit Terjual	Total Publisher Revenue
Amazon Digital Services, Inc.	5.608.343	64.759.679,550
Random House LLC	1.251.876	91.504.569,210
Penguin Group (USA) LLC	797.545	84.363.799,770
HarperCollins Publishers	540.201	70.224.438,750
Simon and Schuster Digital Sales Inc	492.668	22.159.110,720
Hachette Book Group	457.409	47.426.574,420
Macmillan	303.177	15.659.883,120
HarperCollins Publishing	44.358	2.830.806,000
HarperCollins Christian Publishing	41.527	2.135.670,000
Grand Total	**9.537.104**	**401.064.531,540**

Genre Terlaku		
Genre	Total Unit Terjual	Total Gross Sales
fiction	7.748.839	1.621.835,090
nonfiction	1.490.147	206.937,040
children	298.118	13.902,220
Grand Total	**9.537.104**	**1.842.674,350**

Exploratory Data Analysis

Top Author Berdasarkan Rating		
Author	Avg Rating	Total Buku DiRating
J.R. Ward	4,33	722.057
Colleen Hoover	4,33	722.887
Jim Butcher	4,30	830.498
Janet Evanovich	4,15	794.340
Sarah Dessen	4,04	687.798
Nicholas Sparks	3,97	1.036.900
Charlaine Harris	3,96	1.452.827
Lemony Snicket, Brett Helquist	3,95	794.620
Stephen King	3,90	2.588.612
Jodi Picoult	3,89	843.446
Grand Total	**4,04**	**10.473.985**

TOP 10 Author Terlaris		
Author	Total Unit Buku Terjual	Total Jenis Buku
Stephen King	270.824	27
Janet Evanovich	178.200	8
Lemony Snicket, Bret	158.973	8
Jim Butcher	145.827	10
Robert Jordan	126.168	6
Colleen Hoover	123.415	6
Eoin Colfer	105.219	4
L.M. Montgomery	98.064	2
Jeff Kinney	97.793	5
Michael Crichton	89.359	6
Grand Total	**1.393.842**	**82**

Pasar Berdasarkan Bahasa Buku	
Kode Bahasa	Total Unit Terjual
eng	6.921.336
en-US	2.342.075
en-GB	241.915
en-CA	12.805
spa	8.459
fre	6.545
nl	3.969
Grand Total	**9.537.104**

Data Visualization

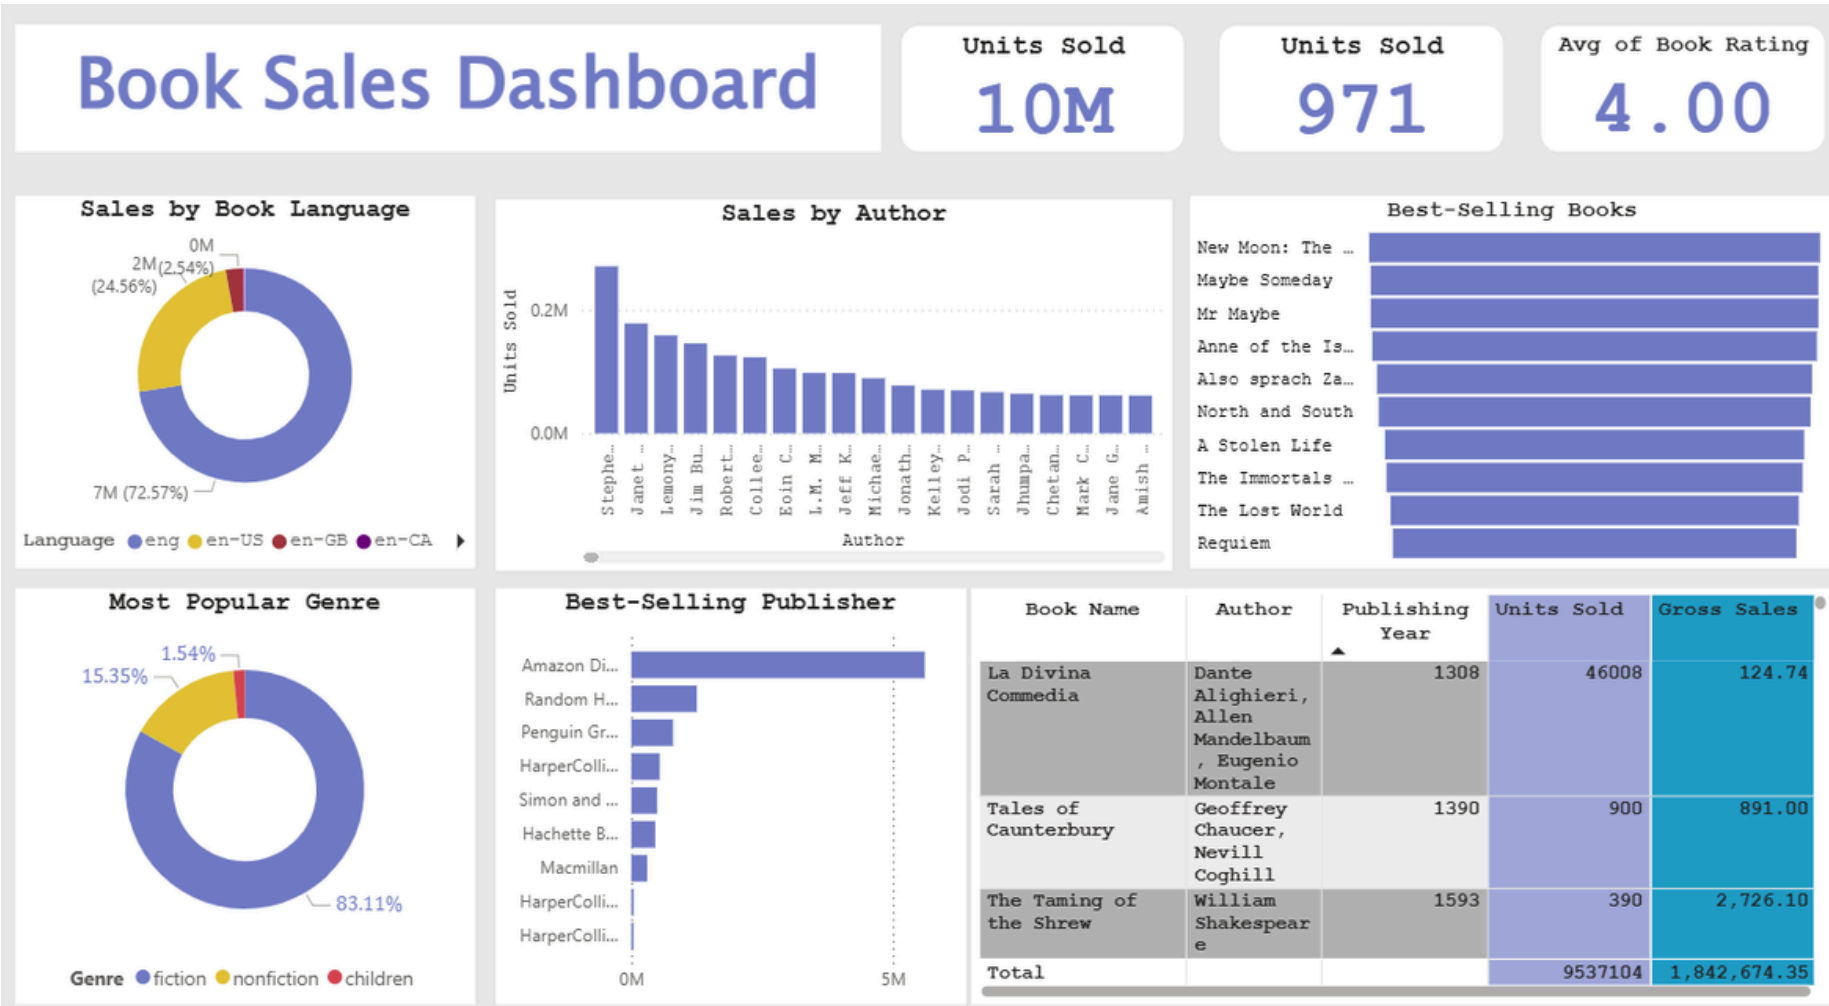

Tools

Power BI

Key Findings

Buku Terlaris "New Moon: The Complete Illustrated Movie Companion" menjadi buku dengan unit terjual tertinggi (61.560 unit) dengan gross sales sebesar $1.560.580, diikuti oleh "Maybe Someday" dan "Mr Maybe".

Publisher Dominan Amazon Digital Services, Inc. memimpin dalam jumlah unit terjual (5.608.343 unit), namun Random House LLC unggul dalam total revenue publisher ($91.504.569.210).

Genre Terlaku Fiction mendominasi pasar secara signifikan dengan 7.748.839 unit terjual (81% dari total), jauh melampaui nonfiction (1.490.147 unit) dan children (298.118 unit).

Author Terlaris & Terbaik Stephen King menjadi author terlaris dengan 270.824 unit dari 27 judul buku. Sementara J.R. Ward dan Colleen Hoover memiliki rating tertinggi (rata-rata 4,33).

Bahasa Buku Novel berbahasa Inggris mendominasi 96% pasar. Bahasa lain (Spanyol, Prancis, Belanda) masih sangat kecil.

Recomendations

Prioritaskan Stok Genre Fiction.
Mengingat fiction menyumbang lebih dari 81% total penjualan, toko buku sebaiknya mengalokasikan porsi stok terbesar untuk genre ini.

Perkuat Kemitraan dengan Publisher Utama.
Tingkatkan kerja sama dengan Amazon Digital Services, Random House LLC, dan Penguin Group melalui negosiasi harga yang lebih kompetitif dan akses awal terhadap judul-judul baru.

Tampilkan Buku dari Author Berating Tinggi di Posisi Utama.
Buku dari J.R. Ward, Colleen Hoover, dan Jim Butcher layak ditampilkan lebih depan karena rating tinggi biasanya jadi pertimbangan utama pembeli sebelum memutuskan beli.

Perkuat Koleksi Buku Bahasa Inggris.
Pastikan stok buku berbahasa Inggris selalu lengkap karena itu yang paling banyak dicari. Kalau ingin coba pasar baru, buku berbahasa Spanyol atau Prancis bisa mulai diperkenalkan dalam jumlah kecil dulu.

Lebih Selektif dalam Memilih Judul Nonfiction dan Children.
Kedua genre ini penjualannya tidak sebesar fiction, jadi perlu lebih hati-hati dalam memilih judul mana yang layak distok agar tidak menumpuk dan tetap menguntungkan.

Conclusion

Dari 971 data buku yang dianalisis, terlihat jelas bahwa fiction adalah genre yang paling dicari, buku berbahasa Inggris menguasai hampir seluruh pasar, dan nama-nama seperti Stephen King serta Random House sudah jadi pilihan utama pembeli.
Rating rata-rata koleksi sebesar 4,00 juga menunjukkan bahwa buku-buku yang ada sudah cukup disukai pembaca.

Temuan ini bisa langsung dipakai sebagai dasar untuk mengatur stok, memilih mitra publisher, dan menentukan arah pengembangan koleksi ke depannya. Kalau ke depan datanya bisa dilengkapi dengan tren penjualan per periode dan data pelanggan, analisisnya tentu bisa jauh lebih tajam dan berguna.

THANK YOU!

Fernando Hasiholan Sinaga
fernandosinaga2002@gmail.com
fernandosinaga123456
@fernandosng_